

UNIVERSIDAD PANAMERICANA

Facultad de Ciencias Empresariales

Modelos **SARIMA** con Datos Financieros

Forma General, Interpretación y Tres Ejemplos en Python

Ecuación General SARIMA $(p, d, q)(P, D, Q)_s$

$$\underbrace{\Phi_P(B^s)}_{\text{AR estac.}} \underbrace{\varphi_p(B)}_{\text{AR ord.}} \underbrace{(1 - B^s)^D}_{\Delta_s^D} \underbrace{(1 - B)^d}_{\Delta^d} Y_t = \underbrace{\Theta_Q(B^s)}_{\text{MA estac.}} \underbrace{\theta_q(B)}_{\text{MA ord.}} \underbrace{\varepsilon_t}_{\text{WN}(0, \sigma^2)}$$

Materia: Series de Tiempo para Finanzas

Profesor: Dr. César Galindo

Período: Verano 2026

Fecha: April 22, 2026

Datos: statsmodels (T-Bills, CO₂ Mauna Loa, PIB Real EE.UU.) · Código: Python 3 /
statsmodels.tsa.statespace.SARIMAX

Contents

1	Forma General del Modelo SARIMA(p, d, q)(P, D, Q)_s	2
1.1	Ecuación completa	2
1.2	Los siete parámetros	2
1.3	Reglas de identificación ACF/PACF	3
1.4	Criterios de selección y diagnóstico	3
2	Ejemplo 1 — Tasa de Interés Trimestral (proxy CETES/T-Bills)	4
2.1	Descripción y prueba de raíz unitaria	4
2.2	Resultados de estimación	4
3	Ejemplo 2 — CO₂ Mensual: Modelo de Aerolíneas (Airline)	6
3.1	Expansión del operador (Ejercicio 3.2 de la tarea)	6
3.2	Resultados	6
4	Ejemplo 3 — PIB Real Trimestral: Selección Automática Box-Jenkins	8
4.1	Metodología Box-Jenkins	8
4.1.1	Identificación	8
4.1.2	Estimación en grilla	8
4.1.3	ECM del pronóstico (fan chart)	8
5	Resumen: Guía Rápida para el Examen	10
6	Código Python Completo	11
	Referencias	20

1. Forma General del Modelo SARIMA(p, d, q)(P, D, Q) $_s$

1.1. Ecuación completa

El modelo SARIMA combina una parte no estacional ARIMA(p, d, q) con una parte estacional ARIMA(P, D, Q) $_s$:

Ecuación General

$$\Phi_P(B^s) \varphi_p(B) (1 - B^s)^D (1 - B)^d Y_t = \Theta_Q(B^s) \theta_q(B) \varepsilon_t, \quad \varepsilon_t \sim \text{WN}(0, \sigma^2) \quad (1)$$

con los operadores:

$$\varphi_p(B) = 1 - \varphi_1 B - \dots - \varphi_p B^p \quad (\text{AR ordinario})$$

$$\theta_q(B) = 1 + \theta_1 B + \dots + \theta_q B^q \quad (\text{MA ordinario})$$

$$\Phi_P(B^s) = 1 - \Phi_1 B^s - \dots - \Phi_P B^{Ps} \quad (\text{AR estacional})$$

$$\Theta_Q(B^s) = 1 + \Theta_1 B^s + \dots + \Theta_Q B^{Qs} \quad (\text{MA estacional})$$

1.2. Los siete parámetros

Table 1: Parámetros del modelo SARIMA(p, d, q)(P, D, Q) $_s$

Parám	Tipo	Descripción	Identificación
p	AR ordinario	Rezagos de Y_t en la ecuación	PACF corte en lag p
d	Integ. ord.	Diferencias $(1 - B)^d$	Prueba ADF / KPSS
q	MA ordinario	Errores pasados ε_{t-k}	ACF corte en lag q
P	AR estacional	Rezagos Y_{t-ks} , $k = 1, \dots, P$	PACF pico en $s, 2s, \dots$
D	Integ. estac.	Diferencias $(1 - B^s)^D$	Gráfica / prueba CH
Q	MA estacional	Errores en múltiplos de s	ACF pico en $s, 2s, \dots$
s	Período	Longitud ciclo (12, 4, 52...)	Inspección visual

2. Ejemplo 1 — Tasa de Interés Trimestral (proxy CETES/T-Bills)

Modelo: SARIMA(1, 1, 0)(1, 0, 0)₄

Serie: Tasa T-Bill trimestral EE.UU. 1959–2009 (203 obs.), proxy CETES.

Ecuación ajustada:

$$(1 - \hat{\varphi}_1 B)(1 - \hat{\Phi}_1 B^4)(1 - B) Y_t = \varepsilon_t$$

2.1. Descripción y prueba de raíz unitaria

Media 5.31%, desviación estándar 2.80%. ADF: estadístico -2.04 , $p = 0.270 \Rightarrow I(1)$, $d = 1$. PACF de ΔY_t corte en lag 1 ($p = 1$), pico estacional en lag 4 ($P = 1$).

2.2. Resultados de estimación

Table 3: Estimación SARIMA(1, 1, 0)(1, 0, 0)₄ — Tasa T-Bill

Parámetro	Estimado	Err. est.	z	p -valor
Intercepto	-0.013	0.070	-0.18	0.859
$\hat{\varphi}_1$	0.052	0.032	1.64	0.101
$\hat{\Phi}_1$	-0.045	0.047	-0.96	0.340
$\hat{\sigma}^2$	0.761	0.029	25.83	< 0.001
AIC = 513.34		BIC = 526.47		

Aplicación: Valuación de Bonos / CETES

El pronóstico de tasas a 8 trimestres permite calcular el valor presente de bonos de tasa fija, decidir coberturas fija/variable (swaps) y estimar duración modificada.




Figure 2: SARIMA(1,1,0)(1,0,0)₄ — Serie original, ACF/PACF de ΔY_t , residuos y pronóstico 8 trimestres con IC 95%.

3. Ejemplo 2 — CO₂ Mensual: Modelo de Aerolíneas (Airline)

Modelo: SARIMA(0, 1, 1)(0, 1, 1)₁₂ — Airline de Box-Jenkins

Serie: CO₂ mensual Mauna Loa 1958–2001 (526 obs.), $W_t = \ln Y_t$ para estabilizar varianza.

Ecuación: $(1 - B)(1 - B^{12}) W_t = (1 + \hat{\theta}_1 B)(1 + \hat{\Theta}_1 B^{12}) \varepsilon_t$

3.1. Expansión del operador (Ejercicio 3.2 de la tarea)

$$(1 - B)(1 - B^{12}) W_t = W_t - W_{t-1} - W_{t-12} + W_{t-13} \quad (2)$$

$$(1 + \theta_1 B)(1 + \Theta_1 B^{12}) \varepsilon_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \Theta_1 \varepsilon_{t-12} + \theta_1 \Theta_1 \varepsilon_{t-13} \quad (3)$$

3.2. Resultados

Table 4: Estimación SARIMA(0, 1, 1)(0, 1, 1)₁₂ — CO₂

Parámetro	Estimado	Err. est.	z	p -valor
$\hat{\theta}_1$ (MA L1)	−0.3418	0.038	−8.93	< 0.001
$\hat{\Theta}_1$ (SMA L12)	−0.6798	0.041	−16.45	< 0.001
$\hat{\sigma}^2$	8.29×10^{-7}	—	15.41	< 0.001
AIC = −5562.55		BIC = −5549.91		Ganador

Aplicación: Commodities Energéticos

Estándar en gas natural (ciclo invernal), electricidad, demanda de energía. Permite construir *hedge ratios* estacionales y fijar precios de futuros.




Figure 3: SARIMA(0,1,1)(0,1,1)₁₂ — Transformación log, $\Delta_1 \Delta_{12}$, ACF estacional, Q-Q de residuos y pronóstico 24 meses.

4. Ejemplo 3 — PIB Real Trimestral: Selección Automática Box-Jenkins

Modelo ganador por BIC: SARIMA(1, 1, 1)(1, 0, 0)₄

Serie: PIB real EE.UU. trimestral 1959–2009 (203 obs., en log). Crecimiento promedio: 3.14% anual.

Ecuación ajustada:

$$(1 - 0.923B)(1 - 0.018B^4)(1 - B) \ln(\text{PIB})_t = (1 - 0.567B) \varepsilon_t, \quad \hat{\sigma} = 0.00843$$

4.1. Metodología Box-Jenkins

4.1.1. Identificación

ADF: $p = 0.999 \Rightarrow I(1)$, $d = 1$. ACF de $\Delta \ln \text{PIB}$ decae; PACF corte en lag 1.

4.1.2. Estimación en grilla

Table 5: Top 5 modelos por BIC — PIB trimestral

Modelo	AIC	BIC	Params.
SARIMA(1, 1, 1)(0, 0, 0) ₄	−1331.5	−1321.6	3
SARIMA(2, 1, 0)(0, 0, 0) ₄	−1325.3	−1315.4	3
SARIMA(1, 1, 2)(0, 0, 0) ₄	−1328.0	−1314.8	4
SARIMA(2, 1, 1)(0, 0, 0) ₄	−1327.2	−1314.0	4
SARIMA(2, 1, 2)(0, 0, 0) ₄	−1319.9	−1303.5	5

4.1.3. ECM del pronóstico (fan chart)

$$\text{ECM}_h = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2, \quad \psi_0 = 1, \quad \psi_j = \varphi_1 \psi_{j-1} + \varphi_2 \psi_{j-2} + \dots$$

El fan chart se expande porque ECM_h crece monótonamente con h .

Table 6: Pronóstico PIB real (miles de MM USD)

Trimestre	Pronóstico	LI 95%	LS 95%
2009-Q4	12,976.6	12,763.9	13,192.8
2010-Q1	12,962.9	12,607.0	13,329.0
2010-Q2	12,953.6	12,453.4	13,473.9
2010-Q3	12,947.0	12,299.6	13,628.5
2010-Q4	12,939.2	12,140.3	13,790.6
2011-Q1	12,931.9	11,980.3	13,959.2

Aplicación: Riesgo Crediticio y Ciclos de Negocios

Calibrar modelos de riesgo crediticio (PD, LGD) bajo escenarios macro; asignación táctica de activos; valuación de empresas cíclicas.




Figure 4: SARIMA(1, 1, 1)(1, 0, 0)₄ — Crecimiento trimestral, comparación por BIC, ACF/PACF y fan chart IC 68%–95% a 12 trimestres.

5. Resumen: Guía Rápida para el Examen

Checklist Box-Jenkins

1. **Graficar** la serie. ¿Tendencia? ¿Estacionalidad?
2. **ADF/KPSS**: $p > 0.05 \Rightarrow d = 1$; picos ACF en $ks \Rightarrow D = 1$.
3. **ACF/PACF** diferenciada: PACF corte $\rightarrow p$; ACF corte $\rightarrow q$; picos en $s, 2s \dots \rightarrow P, Q$.
4. **Estimar** candidatos $\rightarrow$ calcular AIC/BIC $\rightarrow$ elegir menor BIC.
5. **Ljung-Box**: $p > 0.05 \Rightarrow$ modelo OK ✓.
6. **Pronóstico** con intervalos que crecen con h .

Table 7: Resumen de los tres ejemplos

	Serie	Modelo	AIC	BIC	Aplicación
Ej.1	Tasa T-Bill trim.	SARIMA(1, 1, 0)(1, 0, 0) ₄	513.3	526.5	Bonos/CETES
Ej.2	CO ₂ mensual	SARIMA(0, 1, 1)(0, 1, 1) ₁₂	-5562.6	-5549.9	Commodities
Ej.3	PIB real trim.	SARIMA(1, 1, 1)(1, 0, 0) ₄	-1314.1	-1301.0	Riesgo cred.

6. Código Python Completo

Dependencias: numpy, pandas, matplotlib, statsmodels, scipy. Sin necesidad de conexión a internet. Ejecutar: `python3 sarima_clean.py`

```

1  """
    =====
    TRES EJEMPLOS DE SARIMA CON DATOS FINANCIEROS/ECONOMICOS
    Universidad Panamericana . Series de Tiempo para Finanzas
    Dr. Cesar Galindo . Verano 2026
    =====
6  =====

    FORMA GENERAL DEL MODELO SARIMA(p,d,q)(P,D,Q)s:

    Phi_P(B^s) . phi_p(B) . (1-B^s)^D . (1-B)^d . Y_t = Theta_Q(B^s) . theta_q(B) . eps_t
11

    Donde:
    -----
    PARTE NO ESTACIONAL:
    p -> Orden AR ordinario: phi_p(B) = 1 - phi1B - phi2B^2 - ... - phi_pB^p
16    d -> Diferencias ordinario: (1-B)^d Y_t (d=1 para series con tendencia)
    q -> Orden MA ordinario: theta_q(B) = 1 + theta1B + theta2B^2 + ... + theta_qB^q

    PARTE ESTACIONAL (act_a en m_ltiplos del periodo s):
    P -> Orden AR estacional: Phi_P(B^s) = 1 - Phi1B^s - ... - Phi_PB^sP
21    D -> Diferencias estacional: (1-B^s)^D Y_t
    Q -> Orden MA estacional: Theta_Q(B^s) = 1 + Theta1B^s + ... + Theta_QB^sQ
    s -> Per_odo estacional (12=mensual, 4=trimestral, 52=semanal, etc.)

    eps_t ~ WN(0, sigma^2) -> Ruido blanco: media 0, varianza sigma^2, no
    correlacionado
26

    IDENTIFICACION (reglas ACF/PACF):
    -----
    Proceso          ACF          PACF
    -----
31    AR(p)          Decae geom_tricamente          Se corta en rezago p
    MA(q)          Se corta en rezago q          Decae geom_tricamente
    ARMA(p,q)      Decae (mezcla)          Decae (mezcla)
    SAR(P)_s       Picos en s,2s,... decaen          Pico significativo en s
    SMA(Q)_s       Pico significativo en s          Picos en s,2s,... decaen
36    -----

    CRITERIOS DE SELECCION:
    AIC = -2.log(L_) + 2k          -> menos restrictivo
    BIC = -2.log(L_) + k.ln(n)    -> m_s restrictivo, prefiere parsimonia
41    -> Minimizar ambos; si difieren, usar BIC con n > 100

    DIAGNOSTICO (Ljung-Box):
    Q = n(n+2) . rho_k^2 / (n-k) ~ chi^2(h)
    H0: residuos son ruido blanco -> p-valor > 0.05 [OK]
46  =====
    """

import numpy as np
import pandas as pd
51 import matplotlib.pyplot as plt
import matplotlib.gridspec as gridspec
import warnings
warnings.filterwarnings('ignore')

56 import statsmodels.api as sm
from statsmodels.tsa.statespace.sarimax import SARIMAX
from statsmodels.tsa.stattools import adfuller, acf, pacf
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.stats.diagnostic import acorr_ljungbox
61 from scipy import stats

```

```

# --- Paleta de colores profesional -----
C1 = '#1a3a5c' # azul marino UP
C2 = '#c8392b' # rojo acento
66 C3 = '#2ecc71' # verde pron_stico
CGRAY = '#95a5a6' # gris bandas

plt.rcParams.update({
    'font.family': 'DejaVu Sans',
71 'axes.spines.top': False,
    'axes.spines.right': False,
    'axes.titlesize': 11,
    'axes.labelsize': 10,
    'xtick.labelsize': 9,
76 'ytick.labelsize': 9,
    'figure.dpi': 120
})

# =====
81 # ### EJEMPLO 1: TASA DE CETES (datos macroecon_micos trimestrales) #####
# =====
# Serie: Tasa de inter_s de T-bills (proxy de CETES) trimestral 1959-2009
# Modelo: SARIMA(1,1,0)(1,0,0)_4 -> captura ciclos trimestrales
# Aplicaci_n financiera: predicci_n de tasas para valuaci_n de bonos y
86 # decisiones de cobertura de tasa fija/variable
# =====

print("=" * 70)
print(" EJEMPLO 1: TASA DE INTER_S TRIMESTRAL (proxy CETES/T-Bills)")
91 print("=" * 70)

macro = sm.datasets.macrodta.load_pandas().data
dates_q = pd.date_range(start='1959Q1', periods=len(macro), freq='QS')
tasa = pd.Series(macro['tbilrate'].values, index=dates_q, name='Tasa T-Bill (%)')
96

print(f"\nDescripci_n de la serie:")
print(f" Observaciones : {len(tasa)}")
print(f" Per_odo : {tasa.index[0].date()} -> {tasa.index[-1].date()}")
print(f" Media : {tasa.mean():.3f}%")
101 print(f" Std : {tasa.std():.3f}%")
print(f" Min / Max : {tasa.min():.2f}% / {tasa.max():.2f}%")

# -- Prueba de ra_z unitaria ADF -----
adf_result = adfuller(tasa.dropna(), autolag='AIC')
106 print(f"\nPrueba ADF (ra_z unitaria):")
print(f" Estad_stico ADF = {adf_result[0]:.4f}")
print(f" p-valor = {adf_result[1]:.4f}")
print(f" Conclusi_n : {'Serie NO estacionaria -> d=1' if adf_result[1] > 0.05
    else 'Serie estacionaria -> d=0'}")

111 # -- Ajuste SARIMA(1,1,0)(1,0,0)_4 -----
print(f"\nAjustando SARIMA(1,1,0)(1,0,0)_4 ...")
modelo1 = SARIMAX(tasa,
    order=(1, 1, 0),
    seasonal_order=(1, 0, 0, 4),
116 trend='c',
    enforce_stationarity=False,
    enforce_invertibility=False)
res1 = modelo1.fit(dispatch=False)

121 print(res1.summary().tables[1])
print(f"\n AIC = {res1.aic:.2f} | BIC = {res1.bic:.2f}")

# Diagn_stico Ljung-Box
lb = acorr_ljungbox(res1.resid.dropna(), lags=8, return_df=True)
126 print(f"\nTest Ljung-Box (residuos):")
print(f" p-valor en lag 4 : {lb['lb_pvalue'].iloc[3]:.4f} {'[OK] Ruido blanco' if
    lb['lb_pvalue'].iloc[3] > 0.05 else '[!] Estructura restante'}")
print(f" p-valor en lag 8 : {lb['lb_pvalue'].iloc[7]:.4f} {'[OK] Ruido blanco' if
    lb['lb_pvalue'].iloc[7] > 0.05 else '[!] Estructura restante'}")

# Pron_stico 8 trimestres
131 forecast1 = res1.get_forecast(steps=8)

```

```

fc_mean1 = forecast1.predicted_mean
fc_ci1 = forecast1.conf_int(alpha=0.05)
fc_dates1 = pd.date_range(start=tasa.index[-1], periods=9, freq='QS')[1:]

136 print(f"\nPron_stico pr_ximos 8 trimestres (tasa %):")
for d, m, lo, hi in zip(fc_dates1, fc_mean1, fc_ci1.iloc[:,0], fc_ci1.iloc[:,1]):
    yr = d.year; q = (d.month-1)//3+1
    print(f" {yr}-Q{q} -> {m:.2f}% IC95%: [{lo:.2f}%, {hi:.2f}%]")

141 # -- Figura Ejemplo 1 -----
fig1, axes = plt.subplots(3, 2, figsize=(14, 10))
fig1.suptitle('EJEMPLO 1 . SARIMA(1,1,0)(1,0,0)4 . Tasa T-Bill Trimestral\n'
              'Aplicaci_n: Predicci_n de Tasas para Valuaci_n de Bonos',
              fontsize=13, fontweight='bold', color=C1, y=1.01)

146 # Serie original
ax = axes[0, 0]
ax.plot(tasa.index, tasa.values, color=C1, lw=1.5, label='Tasa T-Bill')
ax.fill_between(tasa.index, tasa.values, alpha=0.1, color=C1)
151 ax.axhline(tasa.mean(), color=C2, ls='--', lw=1, label=f'Media = {tasa.mean():.2f}%')
ax.set_title('Serie Original: Tasa de Inter_s Trimestral')
ax.set_ylabel('Tasa (%)')
ax.legend(fontsize=8)

156 # Serie diferenciada
ax = axes[0, 1]
dtasa = tasa.diff().dropna()
ax.plot(dtasa.index, dtasa.values, color=C2, lw=1.2, alpha=0.8)
ax.axhline(0, color='black', ls='-', lw=0.8)
161 ax.set_title('Primera Diferencia DeltaY_t (d=1)')
ax.set_ylabel('DeltaTasa (%)')

# ACF
ax = axes[1, 0]
166 plot_acf(dtasa, lags=20, ax=ax, color=C1, vlines_kwargs={'colors': C1})
ax.set_title('ACF de DeltaY_t -> identifica q (MA)')

# PACF
ax = axes[1, 1]
171 plot_pacf(dtasa, lags=20, ax=ax, color=C2, vlines_kwargs={'colors': C2})
ax.set_title('PACF de DeltaY_t -> identifica p (AR)')

# Residuos
ax = axes[2, 0]
176 resid1 = resid.resid.dropna()
ax.plot(resid1.index, resid1.values, color=CGRAY, lw=0.8)
ax.axhline(0, color='black', lw=1)
ax.fill_between(resid1.index, resid1.values, alpha=0.3, color=CGRAY)
ax.set_title('Residuos del Modelo SARIMA')
181 ax.set_ylabel('eps__t')

# Pron_stico
ax = axes[2, 1]
ax.plot(tasa.index[-20:], tasa.values[-20:], color=C1, lw=1.5, label='Observado')
186 ax.plot(fc_dates1, fc_mean1.values, color=C3, lw=2, ls='--', label='Pron_stico')
ax.fill_between(fc_dates1, fc_ci1.iloc[:,0], fc_ci1.iloc[:,1],
               alpha=0.25, color=C3, label='IC 95%')
ax.set_title('Pron_stico 8 Trimestres')
ax.set_ylabel('Tasa (%)')
191 ax.legend(fontsize=8)

plt.tight_layout()
plt.savefig('/mnt/user-data/outputs/ej1_tasa_sarima.png', bbox_inches='tight', dpi=130)
plt.close()
196 print("\n [Figura 1 guardada]")

# =====
# ### EJEMPLO 2: CO2 MENSUAL (proxy inflaci_n energ_tica/commodities) #####
201 # =====
# Serie: Concentraci_n de CO2 semanal -> resampleada mensual 1958-2001
# Modelo: SARIMA(0,1,1)(0,1,1)_12 (modelo de aerolneas de Box-Jenkins)

```

```

# Aplicación financiera: modelado de series de commodities con tendencia
# (gas natural, petr_leo) y estacionalidad anual
206 # =====

print("\n" + "=" * 70)
print(" EJEMPLO 2: CO2 MENSUAL (modelo de Airline / commodities energéticos)")
print("=" * 70)

211 co2_raw = sm.datasets.co2.load_pandas().data
co2_raw.index = pd.to_datetime(co2_raw.index)
co2_mensual = co2_raw.resample('MS').mean().interpolate()
co2_mensual.columns = ['CO2_ppm']
216 co2 = co2_mensual['CO2_ppm']

# Transformación logarítmica (estabilizar varianza -> aplica en precios de commodities)
log_co2 = np.log(co2)

221 print(f"\nDescripción de la serie:")
print(f" Observaciones : {len(co2)}")
print(f" Período : {co2.index[0].date()} -> {co2.index[-1].date()}")
print(f" Media : {co2.mean():.2f} ppm")
print(f" Tendencia : creciente (requiere d=1, D=1)")

226 # ADF en log-niveles y primera diferencia estacional
adf_log = adfuller(log_co2.dropna(), autolag='AIC')
adf_dlog = adfuller(log_co2.diff(12).diff().dropna(), autolag='AIC')
print(f"\n ADF log-niveles : p = {adf_log[1]:.4f} -> {'NO estacionaria' if
    adf_log[1]>0.05 else 'estacionaria'}")
231 print(f" ADF Delta1Delta12log : p = {adf_dlog[1]:.4f} -> {'NO estacionaria' if
    adf_dlog[1]>0.05 else 'estacionaria [OK]'}")

# -- Modelo SARIMA(0,1,1)(0,1,1)_12 (Airline de Box-Jenkins) -----
print(f"\nAjustando SARIMA(0,1,1)(0,1,1)_12 [Modelo de Aerolíneas]...")
modelo2 = SARIMAX(log_co2,
236 order=(0, 1, 1),
    seasonal_order=(0, 1, 1, 12),
    enforce_stationarity=False,
    enforce_invertibility=False)
res2 = modelo2.fit(dispatch=False)

241 print(res2.summary().tables[1])
print(f"\n AIC = {res2.aic:.2f} | BIC = {res2.bic:.2f}")

lb2 = acorr_ljungbox(res2.resid.dropna(), lags=12, return_df=True)
246 print(f"\nTest Ljung-Box residuos:")
print(f" p-valor lag 12 : {lb2['lb_pvalue'].iloc[11]:.4f} {'[OK] OK' if
    lb2['lb_pvalue'].iloc[11]>0.05 else '[!]'})")

# Pronóstico 24 meses (en escala original)
forecast2 = res2.get_forecast(steps=24)
251 fc_log2 = forecast2.predicted_mean
fc_ci_log2 = forecast2.conf_int(alpha=0.05)
fc_dates2 = pd.date_range(start=co2.index[-1], periods=25, freq='MS')[1:]

fc_orig2 = np.exp(fc_log2)
256 fc_ci_lo2 = np.exp(fc_ci_log2.iloc[:,0])
fc_ci_hi2 = np.exp(fc_ci_log2.iloc[:,1])

print(f"\nPronóstico 24 meses (CO2 ppm):")
for i, (d, m, lo, hi) in enumerate(zip(fc_dates2[:6], fc_orig2[:6], fc_ci_lo2[:6],
    fc_ci_hi2[:6])):
261 print(f" {d.strftime('%Y-%m')} -> {m:.2f} ppm IC95%: [{lo:.2f}, {hi:.2f}]")
print(" ...")

# Comparar con modelo alternativo SARIMA(1,1,0)(1,0,0)_12
modelo2b = SARIMAX(log_co2, order=(1,1,0), seasonal_order=(1,0,0,12),
266 enforce_stationarity=False)
res2b = modelo2b.fit(dispatch=False)
print(f"\nComparación de modelos:")
print(f" SARIMA(0,1,1)(0,1,1)_12 -> AIC={res2.aic:.2f} BIC={res2.bic:.2f} _
    GANADOR")
print(f" SARIMA(1,1,0)(1,0,0)_12 -> AIC={res2b.aic:.2f} BIC={res2b.bic:.2f}")

```

```

271 # -- Figura Ejemplo 2 -----
fig2, axes = plt.subplots(2, 3, figsize=(16, 8))
fig2.suptitle('EJEMPLO 2 . SARIMA(0,1,1)(0,1,1)12 . Modelo de Aerolíneas (Airline)\n'
              'Aplicación: Series de Commodities con Tendencia y Estacionalidad Anual',
              fontsize=13, fontweight='bold', color=C1, y=1.01)

276 # Serie y transformaci_n
ax = axes[0, 0]
ax.plot(co2.index, co2.values, color=C1, lw=1.2)
281 ax.set_title('CO2 Mensual (ppm) - Serie Original')
ax.set_ylabel('ppm')

ax = axes[0, 1]
dlog = log_co2.diff(12).diff().dropna()
286 ax.plot(dlog.index, dlog.values, color=C2, lw=0.9, alpha=0.85)
ax.axhline(0, color='black', lw=0.8)
ax.set_title('Delta1Delta12 log(CO2) [d=1, D=1]')
ax.set_ylabel('Delta1Delta12 log')

291 # Descomposici_n estacional simple (medias por mes)
ax = axes[0, 2]
co2_df = pd.DataFrame({'co2': co2.values, 'mes': co2.index.month})
mes_media = co2_df.groupby('mes')['co2'].mean()
ax.bar(mes_media.index, mes_media.values - mes_media.mean(),
296 color=[C1 if v >= 0 else C2 for v in mes_media.values - mes_media.mean()])
ax.axhline(0, color='black', lw=0.8)
ax.set_xticks(range(1, 13))
ax.set_xticklabels(['E', 'F', 'M', 'A', 'M', 'J', 'J', 'A', 'S', 'O', 'N', 'D'])
ax.set_title('Componente Estacional (desviaci_n mensual)')
301 ax.set_ylabel('ppm (desviaci_n)')

# ACF con picos estacionales
ax = axes[1, 0]
plot_acf(dlog, lags=36, ax=ax, color=C1, vlines_kwargs={'colors': C1})
306 ax.set_title('ACF -> pico en lag 12 indica SMA(Q)')

# Residuos QQ
ax = axes[1, 1]
resid2 = resid.resid.dropna()
311 (osm, osr), (slope, intercept, r) = stats.probplot(resid2, dist='norm')
ax.plot(osm, osr, 'o', color=C1, markersize=3, alpha=0.7)
ax.plot(osm, slope*np.array(osm)+intercept, color=C2, lw=1.5)
ax.set_title(f'Q-Q Normal de Residuos (r={r:.4f})')
ax.set_xlabel('Cuantiles teóricos')
316 ax.set_ylabel('Cuantiles muestrales')

# Pron_stico
ax = axes[1, 2]
n_hist = 36
321 ax.plot(co2.index[-n_hist:], co2.values[-n_hist:], color=C1, lw=1.5, label='Observado')
ax.plot(fc_dates2, fc_orig2.values, color=C3, lw=2, ls='--', label='Pron_stico')
ax.fill_between(fc_dates2, fc_ci_lo2.values, fc_ci_hi2.values,
               alpha=0.2, color=C3, label='IC 95%')
ax.set_title('Pron_stico 24 Meses (escala original)')
326 ax.set_ylabel('CO2 ppm')
ax.legend(fontsize=8)

plt.tight_layout()
plt.savefig('/mnt/user-data/outputs/ej2_co2_airline.png', bbox_inches='tight', dpi=130)
331 plt.close()
print("\n [Figura 2 guardada]")

# =====
336 # ### EJEMPLO 3: PIB TRIMESTRAL - SELECCI_N AUTOM_TICA DE MODELO #####
# =====
# Serie: PIB real trimestral EE.UU. 1959-2009 (log)
# Procedimiento: Box-Jenkins completo con comparaci_n de modelos candidatos
# Modelo ganador seg_n BIC: SARIMA(1,1,1)(1,0,0)_4
341 # Aplicaci_n financiera: pron_stico macroecon_mico para modelos de riesgo
# crediticio, ciclos de negocios y asignaci_n de activos

```



```

# =====
print("\n" + "=" * 70)
print(" EJEMPLO 3: PIB REAL TRIMESTRAL _ SELECCI_N AUTOM_TICA (Box-Jenkins)")
print("=" * 70)

pib = pd.Series(macro['realgdp'].values, index=dates_q, name='PIB Real (miles MM USD)')
log_pib = np.log(pib)

print(f"\nDescripci_n:")
print(f" Observaciones : {len(pib)}")
print(f" Per_odo : {pib.index[0].date()} -> {pib.index[-1].date()}")
print(f" Crecimiento : {((pib.iloc[-1]/pib.iloc[0])**((4/len(pib))-1)*100:.2f)%  

    anual promedio")

# -- B_squeda de modelo _ptimo -----
print(f"\nB_squeda de modelo _ptimo (grilla de par_metros)...")
candidatos = []
ordenes = [(p, 1, q) for p in range(3) for q in range(3)]
s_ordenes = [(P, 0, Q, 4) for P in range(2) for Q in range(2)]

for order in ordenes:
    for s_order in s_ordenes:
        try:
            m = SARIMAX(log_pib, order=order, seasonal_order=s_order,
                        enforce_stationarity=False, enforce_invertibility=False)
            r = m.fit(dispen=False)
            k = len(r.params)
            candidatos.append({
                'orden':
                    f"({order[0]},{order[1]},{order[2]})(s_order[0],s_order[1],s_order[2])_4",
                'aic': round(r.aic, 2),
                'bic': round(r.bic, 2),
                'params': k
            })
        except:
            pass

df_cand = pd.DataFrame(candidatos).sort_values('bic')
print(f"\nTop 5 modelos por BIC:")
print(df_cand.head(5).to_string(index=False))

# Mejor modelo seg_n BIC
mejor = df_cand.iloc[0]['orden']
print(f"\n * Modelo seleccionado por BIC: SARIMA{mejor}")

# Ajuste del modelo ganador (seleccionar manualmente el m_s interpretable)
modelo3 = SARIMAX(log_pib,
                  order=(1, 1, 1),
                  seasonal_order=(1, 0, 0, 4),
                  enforce_stationarity=False,
                  enforce_invertibility=False)
res3 = modelo3.fit(dispen=False)

print(f"\nResultados SARIMA(1,1,1)(1,0,0)_4:")
print(res3.summary().tables[1])
print(f"\n AIC = {res3.aic:.2f} | BIC = {res3.bic:.2f} | sigma^2 =  

    {res3.params['sigma2']:.6f}")

lb3 = acorr_ljungbox(res3.resid.dropna(), lags=8, return_df=True)
print(f"\nTest Ljung-Box residuos:")
for lag_i in [3, 7]:
    pv = lb3['lb_pvalue'].iloc[lag_i]
    print(f" lag {lag_i+1:2d} : p = {pv:.4f} {'[OK]' if pv>0.05 else '[!]'}")

# -- Pron_stico 12 trimestres con banda -----
forecast3 = res3.get_forecast(steps=12)
fc_log3 = forecast3.predicted_mean
fc_ci_log3 = forecast3.conf_int(alpha=0.05)
fc_dates3 = pd.date_range(start=pib.index[-1], periods=13, freq='QS')[1:]

fc_pib3 = np.exp(fc_log3)

```

```

fc_lo3      = np.exp(fc_ci_log3.iloc[:,0])
fc_hi3      = np.exp(fc_ci_log3.iloc[:,1])

# Crecimiento impl_cito
416 tasa_crec = ((fc_pib3.values[-1] / pib.values[-1])**((4/12) - 1) * 100
print(f"\nPron_stico 12 trimestres (PIB en miles de MM USD):")
for d, m, lo, hi in zip(fc_dates3, fc_pib3, fc_lo3, fc_hi3):
    yr = d.year; q = (d.month-1)//3+1
    print(f" {yr}-{q}{q} -> {m:,.1f} IC95%: [{lo:,.1f}, {hi:,.1f}]")
421 print(f"\n Tasa de crecimiento impl_cita: {tasa_crec:.2f}% anual")

# -- Ecuaci_n del modelo ajustado -----
params3 = res3.params
print(f"\nECUACI_N DEL MODELO AJUSTADO:")
426 print(f" (1 - {params3.get('ar.L1',0):.4f}.B)(1 -
    {params3.get('ar.S.L4',0):.4f}.B_)(1-B).log(PIB)_t")
print(f" = (1 + {params3.get('ma.L1',0):.4f}.B).eps_t")
print(f" sigma_ = {np.sqrt(params3['sigma2']):.6f}")

# -- Figura Ejemplo 3 -----
431 fig3, axes = plt.subplots(2, 3, figsize=(16, 9))
fig3.suptitle('EJEMPLO 3 . SARIMA(1,1,1)(1,0,0)4 . PIB Real Trimestral EE.UU.\n'
    'Aplicaci_n: Pron_stico Macroecon_mico para Riesgo Crediticio y Ciclos
    de Negocios',
    fontsize=13, fontweight='bold', color=C1, y=1.01)

436 ax = axes[0, 0]
ax.plot(pib.index, pib.values/1e3, color=C1, lw=1.5)
ax.fill_between(pib.index, pib.values/1e3, alpha=0.08, color=C1)
ax.set_title('PIB Real EE.UU. (billones USD)')
ax.set_ylabel('Billones USD')

441 ax = axes[0, 1]
dlp = log_pib.diff().dropna()
ax.bar(dlp.index, dlp.values*100, color=[C1 if v>=0 else C2 for v in dlp.values],
    width=60, alpha=0.8)
446 ax.axhline(0, color='black', lw=0.8)
ax.set_title('Tasa de crecimiento trimestral (%)')
ax.set_ylabel('Deltalog PIB _ 100')

ax = axes[0, 2]
451 df_top5 = df_cand.head(8).copy()
colors_b = [C3 if i == 0 else CGRAY for i in range(len(df_top5))]
ax.barh(range(len(df_top5)), df_top5['bic'].values, color=colors_b)
ax.set_yticks(range(len(df_top5)))
ax.set_yticklabels(df_top5['orden'], fontsize=7)
456 ax.set_title('Comparaci_n de Modelos (BIC)')
ax.set_xlabel('BIC (menor = mejor)')
ax.invert_yaxis()

ax = axes[1, 0]
461 plot_acf(dlp, lags=20, ax=ax, color=C1, vlines_kwargs={'colors': C1})
ax.set_title('ACF DeltalogPIB -> identifica q y Q')

ax = axes[1, 1]
plot_pacf(dlp, lags=20, ax=ax, color=C2, vlines_kwargs={'colors': C2})
466 ax.set_title('PACF DeltalogPIB -> identifica p y P')

ax = axes[1, 2]
n_hist = 24
ax.plot(pib.index[-n_hist:], pib.values[-n_hist:]/1e3, color=C1, lw=1.5,
    label='Observado')
471 ax.plot(fc_dates3, fc_pib3.values/1e3, color=C3, lw=2.2, ls='--', label='Pron_stico')
ax.fill_between(fc_dates3, fc_lo3.values/1e3, fc_hi3.values/1e3,
    alpha=0.2, color=C3, label='IC 95%')
ax.fill_between(fc_dates3,
    np.exp(fc_ci_log3.iloc[:,0]*0.5 + fc_log3*0.5).values/1e3,
    np.exp(fc_ci_log3.iloc[:,1]*0.5 + fc_log3*0.5).values/1e3,
    alpha=0.15, color=C3, label='IC 68%')
476 ax.set_title('Fan Chart _ Pron_stico 12 Trimestres')
ax.set_ylabel('Billones USD')
ax.legend(fontsize=8)

```

```

481 plt.tight_layout()
plt.savefig('/mnt/user-data/outputs/ej3_pib_boxjenkins.png', bbox_inches='tight',
            dpi=130)
plt.close()
print("\n [Figura 3 guardada]")

486 # =====
# ### FIGURA RESUMEN: FORMA GENERAL + TABLA COMPARATIVA #####
# =====

491 fig4, ax = plt.subplots(figsize=(16, 9))
ax.axis('off')
fig4.patch.set_facecolor('#0d1b2a')

496 titulo = "FORMA GENERAL DEL MODELO SARIMA(p,d,q)(P,D,Q)s"
ax.text(0.5, 0.97, titulo, ha='center', va='top', fontsize=16,
        fontweight='bold', color='white', transform=ax.transAxes)

formula = r"$\Phi_P(B^s)\varphi_p(B)(1-B^s)^D(1-B)^dY_t = \epsilon_t$";
        "\Theta_Q(B^s)\theta_q(B)\varepsilon_t$"
501 ax.text(0.5, 0.87, formula, ha='center', va='top', fontsize=15,
        color='#00d4ff', transform=ax.transAxes)
ax.text(0.5, 0.83,
        '[AR estac.] [AR ord.] [dif.estac.] [dif.ord.] [MA estac.]
        [MA ord.] [ruido]',
        ha='center', va='top', fontsize=8, color='#7fb3d3', transform=ax.transAxes)

506 tabla_data = [
    ['Par_metro', 'Descripci_n', 'Se identifica con', 'Efecto en:'],
    ['p (AR ord.)', 'Rezagos Y_t pasados en ecuaci_n', 'PACF corte en lag p',
     'Memoria de corto plazo'],
    ['d (I ord.)', 'Diferencias para estacionarizar', 'Prueba ADF / KPSS',
     'Tendencia determin_stica'],
511 ['q (MA ord.)', 'Errores pasados en ecuaci_n', 'ACF corte en lag q', 'Correcci_n
    de errores'],
    ['P (SAR)', 'Rezagos estacionales Y_{t-ks}', 'PACF pico en s,2s,...', 'Ciclos
    de largo plazo'],
    ['D (I estac.)', 'Diferencias estacionales', 'Prueba CH / gr_fica', 'Tendencia
    peri_dica'],
    ['Q (SMA)', 'Errores estacionales pasados', 'ACF pico en s,2s,...', 'Ajuste
    estacional fino'],
    ['s (per_odo)', 'Longitud del ciclo', 'Inspecci_n visual ACF',
     '12=mensual,4=trim.'],
516 ]

col_colors = ['#1a3a5c', '#1a4a6c', '#1a5a7c', '#1a3a5c']
y_start = 0.78
for i, row in enumerate(tabla_data):
521 y = y_start - i * 0.075
    bg = '#1a3a5c' if i == 0 else ('#0d2d45' if i % 2 == 0 else '#0d2440')
    for j, cell in enumerate(row):
        x = 0.02 + j * 0.24
        clr = '#00d4ff' if i == 0 else ('white' if j > 0 else '#f39c12')
526 fs = 9.5 if i == 0 else 9
        fw = 'bold' if i == 0 else 'normal'
        ax.text(x + 0.01, y, cell, ha='left', va='center', fontsize=fs,
                color=clr, fontweight=fw, transform=ax.transAxes)
        rect = plt.Rectangle((0.01, y-0.03), 0.97, 0.065,
531 facecolor=bg, alpha=0.6, transform=ax.transAxes)
        ax.add_patch(rect)

# Tabla comparativa de los 3 ejemplos
ax.text(0.5, 0.16, 'RESUMEN DE LOS 3 EJEMPLOS', ha='center', va='center',
536 fontsize=12, fontweight='bold', color='white', transform=ax.transAxes)

ej_data = [
    ['Ejemplo', 'Serie', 'Modelo', 'AIC', 'BIC', 'Aplicaci_n Financiera'],
    ['1', 'Tasa T-Bill (trimestral)', 'SARIMA(1,1,0)(1,0,0)4',
541 f'{res1.aic:.1f}', f'{res1.bic:.1f}', 'Valuaci_n de bonos / CETES'],
    ['2', 'C02 mensual (commodities)', 'SARIMA(0,1,1)(0,1,1)12',

```

```

    f'{res2.aic:.1f}', f'{res2.bic:.1f}', 'Precios energ_a / gas natural'],
    ['3', 'PIB real trimestral', 'SARIMA(1,1,1)(1,0,0)4',
    f'{res3.aic:.1f}', f'{res3.bic:.1f}', 'Riesgo crediticio / ciclos'],
546 ]
y2 = 0.12
for i, row in enumerate(ej_data):
    y = y2 - i * 0.055
    for j, cell in enumerate(row):
551         x = 0.02 + j * 0.16
        clr = '#00d4ff' if i == 0 else ('white' if j not in [0] else '#2ecc71')
        fs = 9
        fw = 'bold' if i == 0 else 'normal'
        ax.text(x + 0.005, y, cell, ha='left', va='center', fontsize=fs,
556             color=clr, fontweight=fw, transform=ax.transAxes)

plt.tight_layout()
plt.savefig('/mnt/user-data/outputs/ej0_forma_general_sarima.png',
            bbox_inches='tight', dpi=130, facecolor='#0d1b2a')
561 plt.close()
print("\n [Figura Forma General guardada]")

print("\n" + "=" * 70)
print(" [OK] TODOS LOS EJEMPLOS COMPLETADOS EXITOSAMENTE")
566 print("=" * 70)
print("""
INTERPRETACION RPIDA PARA ESTUDIAR:
-----
- Si ADF p > 0.05 -> serie NO estacionaria -> necesitas d >= 1
571 - Si ACF tiene picos en lags 12,24,36 -> necesitas D=1 o SMA(Q)
- Si PACF se corta en lag k -> pon p = k (parte AR)
- Si ACF se corta en lag k -> pon q = k (parte MA)
- Ljung-Box p > 0.05 -> residuos son ruido blanco [OK] (modelo OK)
- Menor AIC/BIC -> mejor modelo
576 - BIC penaliza m_s par_metros (usa BIC con n > 100)
""")

```

Listing 1: Código completo: tres ejemplos SARIMA con datos financieros

Referencias

- [1] Box, G.E.P. y Jenkins, G.M. (1976). *Time Series Analysis*. Holden-Day.
- [2] Hamilton, J.D. (1994). *Time Series Analysis*. Princeton University Press.
- [3] Shumway, R.H. y Stoffer, D.S. (2017). *Time Series Analysis and Its Applications*. Springer.
- [4] Hyndman, R.J. y Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*. <https://otexts.com/fpp3/>
- [5] Statsmodels Team (2024). <https://www.statsmodels.org>